

这个世界的未来需要世界来推导

世界语言模型框架：异质判官、互补盲区与现实反馈

MoLinG-666

2026 年 9 月 24 日 · 立场论文 + 初步实验 · v0.3

本版包含首次最小实验；真实 LLM 判官尚未接入，语言判官结果来自仿真。

许可：CC BY-NC 4.0（非商业使用）；任何商业用途均需事先获得 MoLinG-666 的单独书面授权。

摘要

自主科学发现的瓶颈不仅在于生成假设，还在于如何验证海量候选。v0.1 提出用代理判官在现实实验之前进行廉价筛选，并将“判官与生成器的错误相关性”视为核心变量。首次最小实验表明，这个方向**部分成立但需要修正**：判官自身的判别能力仍是表现的主因，错误相关性更适合作为诊断变量；数据驱动代理与语言判官的主要价值不在谁总体更准，而在于**盲区互补**。同时，代理模型在分布外可完全失效，因此“我不知道”的不确定性路由不是附加功能，而是必要条件。

本文据此将架构从“单一独立判官”升级为**异质判官集成 + 不确定性路由 + 现实反馈**。我们保留误收率、误杀率与成本模型，放弃 v0.1 中退化的共振强度定义，改用错误相关系数及按错误类型分解的盲区指标。核心主张变为：**强验证系统需要高判别能力、低错误共振、互补盲区，以及可靠的 OOD/不确定性升级机制**。

1 问题：生成便宜，验证昂贵

大模型可以快速生成大量候选假设，但“想出一个说法”与“知道它是否成立”是两件事。现实实验提供最可靠的反馈，却慢、贵，并可能存在风险。因此自主科学系统需要一个中间验证层，把大量候选压缩成少量值得进入现实实验的对象。

v0.1 的出发点是：如果生成器和判官共享相同盲点，多轮自我批评可能只会重复同一种错误。首次实验没有否定这个问题，但显示原先的强结论过头了：**错误独立性重要，但它不是判官表现的唯一或主导因素**。

2 从“一个好判官”到“多个互补判官”

实验中，语言类判官与数据驱动代理表现出明显不同的错误结构。语言判官更擅长识别量纲错误、明显线性化等“形式上可疑”的候选；代理模拟器更擅长识别耗散、外力、三次项等仅靠符号外观不容易判断的动力学错误。总体准确率接近，但盲区不同。

因此更合理的架构不是寻找一个万能判官，而是使用**异质判官集成**。本文将这一整体闭环命名为**世界语言模型框架**（World Language Model Framework, WLMF）：语言模型负责提出、解释与组织候选，多个异质判官负责从不同失败模式出发进行验证，路由器把不确定、分歧与 OOD 情况升级到现实世界，现实结果再反向修正判官与生成过程。这里的

“世界”不是修辞，而是指**最终判断权必须回到可观测、可实验、可反馈的外部世界**。




图 1 世界语言模型框架（WLMF）的验证闭环：不同判官负责不同类型的错误，路由器把分歧、低置信度和 OOD 候选升级到现实验证。

这个版本允许继续加入新的判官，例如形式证明器、数据库检索器、领域模拟器或真实仪器。关键不是数量，而是它们是否提供**不同的失败模式和独立信息来源**。

3 如何衡量判官

3.1 运营指标

在生成器真实输出上测量：

- $f_p = P(\text{接受} | \text{错误})$ ：误收率；
- $f_n = P(\text{拒绝} | \text{正确})$ ：误杀率；
- 平衡准确率 $1 - (f_p + f_n)/2$ ：对真假候选不平衡更稳健。

这些指标直接决定一个判官在系统里是否值得使用。

3.2 诊断指标：错误相关与盲区

v0.1 定义

$$R_{\text{res}} = P(E_J | E_G) - P(E_J)$$

并试图把它作为独立诊断量。实际执行发现，在单一候选流上该定义会退化成 f_p 与 f_n 的重新组合，不能提供新的相关性信息。因此 v0.2 不再把它作为主指标。

我们改用两类诊断量：

- $\phi = \text{corr}(\text{判官判错}, \text{候选为错})$ ，直接测量错误耦合；

- 按错误类型 k 分解的盲区指标，比较某类错误上的误接受率相对总体或基准池的增量。

这里的目标不是证明“相关性比能力更重要”，而是识别判官在哪些生成器错误上会系统性失效，从而选择互补判官。

4 首次最小实验

4.1 设置

我们实现了 v0.1 提出的单摆与弹簧实验。真实动力学 T^* 只用于最终评分；代理模型 $\hat{T}$ 仅从带噪轨迹学习下一状态。候选池包含正确方程和多类缺陷，包括耗散、注能、周期外力、量纲缩放、偏置、线性化和三次非线性项。

实验实际生成约 7.6×10^4 个候选，并训练多个不同数据量、不同随机种子与不同污染方式的代理模型。由于运行环境没有可用 LLM API，自评/同族/异族语言判官使用固定符号特征进行仿真实现；因此涉及真实 LLM 的结论仅能视为弱证据。

4.2 结果概览

预测	结果	解释
错误相关性越低越好	部分支持	单变量上显著负相关，但控制判官能力后只增加约 3 个百分点解释力，能力仍是主因。
代理模拟器明显优于语言判官	反驳	总体平衡准确率接近；两者优势主要体现在不同错误类型。
代理模拟器在 OOD 失效	强烈支持	代理在 OOD 上可退化为把所有候选都判错， $f_n = 1$ 。

表 1 首次实验对 v0.1 三条主要预测的检验。

54 个判官点上，错误相关性 ϕ 与平衡准确率的 Spearman 相关约为 -0.48 (95% CI $[-0.66, -0.26]$)。但在控制判官自身最佳可达能力后，能力单独解释约 91% 的方差，加入相关性后约为 94%。因此相关性是有效诊断信号，但不是性能主因。

更有信息量的是错误类型分工：代理对耗散、外力、量纲与三次项更强，而语言判官对线性化等显式符号错误更强。这个结果支持“互补判官”而不是“单一代理替代语言判官”。

4.3 因果消融

我们通过污染代理模型的训练轨迹主动改变其失败模式。强污染把错误相关性从约 -0.3 推高到 $+0.4 \sim +0.8$ ，同时平衡准确率从约 0.58 降到约 0.52。这说明：让判官学到与生成器相同的错误模式，确实会让它在这些错误上变盲。细粒度定向污染的种子方差较大，因此该结论仍需更多重复实验。

4.4 OOD：为什么“我不知道”是必要机制

代理模型在分布内的长时 rollout 尚可工作，但在更大摆角、更硬弹簧等 OOD 条件下误差可增加约 50 倍。最极端时，它把所有候选都判为错误，包括全部正确候选，即 $f_n = 1$ 。

因此一个代理判官如果没有可靠的不确定性/OOD 检测，会把真正的新发现与普通错误一起挡掉。系统必须允许：

Accept, Reject, Escalate/Unknown.

5 成本与路由

设候选总数为 N ，真假设比例为 p ，现实实验单次成本 C_r ，代理验证成本 C_s 。若只有二元筛选，通过比例为

$$q = p(1 - f_n) + (1 - p)f_p,$$

则

$$\text{Cost}_1 = NC_s + NqC_r.$$

若漏掉一个真发现的代价为 C_{miss} ，总代价可写为

$$J = NC_s + NqC_r + Npf_nC_{\text{miss}}.$$

首次实验显示，三路分流只有在“错误确实集中在判官自己的低置信度区域”时才有明显收益。语言判官的低置信度路由能降低有效误杀率；代理模型的错误并未充分集中在低置信度区域，收益较小。因此 v0.2 把校准过的不确定性与独立 OOD 检测提升为下一阶段的核心研究问题。

6 局限与下一步

当前证据仍然有限：

- 语言判官为仿真，不代表真实 LLM；
- 生成器为随机程序，而非真实科学 agent；
- 单摆与弹簧是低维 ODE，不能直接外推到开放科学；
- 污染实验只近似“共享训练数据/共享错误模式”；
- 原论文的共振指标已被实验发现存在定义缺陷。

下一步最关键的不是扩大模型，而是做三个更直接的实验：使用真实不同家族 LLM 作为判官；加入独立 OOD 检测器；比较单一最强判官与多判官互补集成。只有当这些结果在更多任务上重复出现，才有资格讨论更大规模的自主科学发现系统。

7 结论

首次实验没有证明“最独立的判官就是最好的判官”。相反，它给出了一个更具体的结论：判官首先必须有足够的判别能力；在能力相近时，错误模式的差异决定了它能为系统补

上哪些盲区。代理模型的价值不是必然比语言判官更准，而是能看到语言判官看不到的错误；语言判官也能看到代理忽略的结构性问题。

因此，本工作的中心从“寻找一个独立判官”转向：

异质判官 + 互补盲区 + 不确定性路由 + 现实反馈

一个真正可靠的自主发现系统，不需要一个永远正确的判官，而需要一组会犯不同错误、并且知道什么时候该把问题交还给现实的判官。

AI 辅助说明

本文在文字起草、语言润色、排版与部分实验实现过程中使用了 AI 工具辅助。研究问题、框架思路、核心主张、实验方向、结果取舍与最终判断由作者 MoLinG-666 提出并决定。AI 工具不列为作者。

许可

本文采用 **Creative Commons Attribution-NonCommercial 4.0 International (CC BY-NC 4.0)** 许可。允许在非商业用途下复制、分享、改编与再发布，但必须署名作者 MoLinG-666。任何商业用途均需事先获得作者的单独书面授权。

参考文献

- [1] D. Silver et al. Mastering the game of Go with deep neural networks and tree search. Nature, 529:484–489, 2016.
- [2] A. Novikov et al. AlphaEvolve: A coding agent for scientific and algorithmic discovery. arXiv:2506.13131, 2025.
- [3] C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, D. Ha. The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv:2408.06292, 2024.
- [4] J. Gottweis, W.-H. Weng, A. Daryin, T. Tu et al. Towards an AI co-scientist. arXiv:2502.18864, 2025.
- [5] Z. Yu et al. Large Discovery Models: Empirically-grounded model-based open-ended search. arXiv:2608.15669, 2026.