

发现为什么需要判官

自主假设生成中的代理判官

MoLinG-666

2026 年 9 月 24 日 · 立场论文 (position paper) · 初稿 v0.1

本文所述实验尚未进行，文中数值与图示均为示意。

摘要

自主科学发现的瓶颈不在生成假设，而在验证假设。纯语言生成与多智能体互评缺少独立的外部反馈，容易形成“幻觉共振”；现实实验能提供真实反馈，却太慢、太贵，无法承受海量试错。为此，我们提议在生成器与现实之间插入一个**代理判官**，先筛掉明显不成立的候选。

本文的核心主张是：**最好的判官不一定是那个最准的，而是错误与生成器最不相关、且验证成本可以接受的那个**。我们给出共振强度的可测量定义、一个说明不完美判官何时值得使用的成本模型，以及一个可在普通电脑上完成的最小实验，并正面列出这一思路最大的未解难题：判官本身从哪来、有多可信。

1 问题：生成便宜，验证才是瓶颈

今天的大模型几秒内就能写出成百上千条“新假设”。生成已不稀缺，稀缺的是判断哪一条是真的。

一个假设要变成知识，必须经过某种能说“不”的检验：实验、观测、数学证明或同行的反驳。没有这一步，再多的想法也只是候选。因此本文关心的是：**当 AI 大规模自主生成假设时，谁来当判官？**我们认为，判官的质量而不是生成器的创造力，决定了整个系统能走多远。

2 为什么自我批评不够

一种流行做法是让多个模型互相提出假设、互相批评。问题并不在于“用语言”：现代模型可以调用工具、检索资料、处理图像。问题在于**生成器和判官的错误高度相关**。参与互评的模型往往来自相似的训练数据，共享相似的盲点；只要评价信号主要来自这些共同的先验，而缺乏独立的外部反馈，自我批评就无法保证纠正共享的错误。

设 E_G 为“生成器提出了错误假设”， E_J 为“判官放过了一个错误假设”。定义共振强度：

$$R_{\text{res}} = P(E_J | E_G) - P(E_J). \quad (1)$$

$R_{\text{res}} > 0$ 说明判官在生成器犯错时比平时更容易一起犯错，我们称之为**幻觉共振**； $R_{\text{res}} \approx 0$

则说明两者的错误近似独立。

总体的 $R_{\text{res}} \approx 0$ 并不代表没有共振：某一类关键错误可能高度相关，另一类却恰好负相关，二者相互抵消。因此实际测量时应按错误类型 k 分组（如违反守恒律、量纲错误、边界条件错误），分别计算 $R_{\text{res}}^{(k)}$ 。

这个定义带来一个直接推论：**判官在通用测试集上的准确率，会高估它在生成器错误上的表现。**一个标准测试中准确率 95% 的判官，面对生成器恰好擅长犯的那类错，实际表现可能差得多。评估判官必须在生成器的真实产出上进行。

3 为什么不能直接用现实验证

现实是最可靠的判官，但代价高昂。一次湿实验可能要几天到几个月，而生成器一分钟就能产出上千个候选；试剂、设备和人工成本使大多数候选不值得检验；在化学、生物、硬件等领域，错误试验还可能带来浪费甚至危险。生成与验证之间的巨大速度差意味着，我们需要一个中间层先把候选数量压下来。

4 提议：代理判官

我们提议在生成器和现实之间插入一个**代理判官**（surrogate judge）：一个能廉价预测候选假设的后果、并给出置信度的近似模型。本文刻意不用“世界模型”一词，因为它如今泛指视频生成、强化学习动力学、潜空间预测器等许多东西，而本文需要的只是其中很窄的一种。系统结构如图 1 所示。




图 1 带三路分流的验证漏斗。代理判官只在有把握时淘汰候选，不确定时交给现实实验。

代理判官不需要完美，但必须比现实快得多，在擅长的范围内足够可信，并且**知道自己**

什么时候不可信。它的任务不是确认真理，而是便宜地说“不”，以及在没把握时老实说“我不知道”。三路分流的意义正在于此：不确定的候选被升级到现实实验而不是直接淘汰，以免把与旧知识冲突的真正新发现误杀。现实实验的结果还要回流修正判官，否则判官的错误会被系统反复利用。

4.1 先例与相关工作

“生成很随意、判官很严格”的模式有成功先例。AlphaGo [1] 中，围棋规则本身就是完美判官；AlphaEvolve [2] 用写定的自动评估器为候选算法打分；生物演化则由环境淘汰随机变异。但这些都是判官**精确或近乎精确**的封闭领域，只能说明廉价可靠的判官有多大威力，不能作为本方案可行的证据。开放科学问题的难处在于，判官只能是对真相的近似。

在开放问题上，AI Scientist [3] 与 AI co-scientist [4] 已实现生成、评审与迭代假设的闭环。与本文最接近的是 Large Discovery Models [5]：它把生成模型与一个贝叶斯代理模型配对，由代理为候选打分、量化不确定性，并随真实实验结果持续更新。本文与这些工作的区别不在“要不要判官”，而在于把**判官与生成器的错误相关性**、误杀代价和验证成本作为评价判官的核心变量。

5 可检验的最小实验：单摆与弹簧

为使本文的主张可以被证伪，我们设计一个最小实验，回答：**一个只从数据学来的代理模拟器，能否可靠地筛掉错误假设？**

1. **准备数据**：用真实物理公式生成单摆和弹簧振子的轨迹（位置、速度随时间变化），加入少量噪声。真实公式记为 T^* ，只在最后评分时使用，模拟器和生成器都看不到它。
2. **训练模拟器**：让神经网络只看轨迹数据学习“下一时刻的状态”，不给任何公式。学到的模拟器记为 $\hat{T}$ 。
3. **生成候选**：让语言模型或随机程序提出一批候选运动方程，部分正确，部分违反能量守恒或量纲不符。
4. **筛选**：让每个候选方程生成轨迹，与 $\hat{T}$ 的预测比较，淘汰偏差大的。
5. **用真相评分**：用 T^* 检查筛选结果，计算误收率 f_p （错误方程被放过的比例）和误杀率 f_n （正确方程被淘汰的比例）。

第 4 步只能说明候选与 $\hat{T}$ 一致，不能说明它正确；正是第 5 步把“与模拟器一致”和“与真相一致”区分开，避免了循环论证。

5.1 核心对比：判官独立程度

为直接检验“判官越独立越好”，我们固定生成器，依次换上独立程度递增的四种判官，并以真实物理作为上限参照（表 1）。

判官	与生成器的关系
生成器自评	同一个模型
同家族的另一个语言模型	相似的训练数据与结构
不同家族的语言模型	训练流程与结构部分独立，但仍可能共享大量公共语料与偏差
学到的代理模拟器 $\hat{T}$	只从轨迹数据学习，不读文本
上限参照：真实物理 T^*	不是判官，只用于最终评分

表 1 独立程度递增的判官。

对每种判官同时测量 $R_{\text{res}}^{(k)}$ 、 f_p 与 f_n 。如果 R_{res} 越低的判官整体表现越好，即使其通用准确率不是最高，就支持了本文的核心主张；否则说明错误相关性并不是关键变量。图 2 给出本文的预期。




图 2 示意图，并非实验结果。各点位置仅表示本文的预期，需由实验验证或推翻。

成功标准是代理模拟器的筛选明显优于纯语言打分。更有意思的测试在训练分布之外（更大摆角、更硬的弹簧）：若模拟器在那里迅速失灵，恰好印证第 7 节的担忧。整个实验在普通电脑上即可完成。

6 成本分析：不完美的判官何时值得用

设候选总数为 N ，其中真假比例 p ；现实实验单次成本为 C_r ，模拟单次成本为 C_s ；判官误收率为 f_p ，误杀率为 f_n 。不用判官时，所有候选都做现实实验：

$$\text{Cost}_0 = NC_r. \quad (2)$$

使用判官时，只有通过筛选的候选才做现实实验，通过比例为 $q = p(1 - f_n) + (1 - p)f_p$ ：

$$\text{Cost}_1 = NC_s + NqC_r. \quad (3)$$

科学上还要计入被误杀的真发现。设漏掉一个真发现的代价为 C_{miss} ，总代价为：

$$J = NC_s + NqC_r + Npf_nC_{\text{miss}}. \quad (4)$$

$J < \text{Cost}_0$ 等价于：

$$\frac{C_s}{C_r} + \frac{pf_nC_{\text{miss}}}{C_r} < 1 - q. \quad (5)$$

左边是模拟的相对成本加上误杀的相对代价，右边是判官挡掉的候选比例。

示意例子（数字为假设）： $p = 1\%$ ， $f_p = 10\%$ ， $f_n = 20\%$ ， $C_s/C_r = 0.001$ 。此时判官挡掉约 89% 的候选，只看实验成本几乎省下九成；但若漏掉一个真发现的代价是一次实验的 1000 倍，误杀的相对代价约为 2，超过了 0.89，判官反而不划算。这是“判官越严格，越可能挡住革命”的定量版本：真假设越稀有、越珍贵， f_n 就越要压低。

三路分流改变了这一取舍。设判官对比例为 u 的候选报告“不确定”并直接送去现实实验，这部分候选不会被误杀，代价是多做 Nu 次实验。只要判官的误杀主要集中在它自己没把握的区域，这样做就能大幅降低 f_n ，而实验成本只小幅上升。

需要强调， f_p 与 f_n 必须在生成器的真实产出上测量，第 2 节的错误相关性已经包含在这两个数字里。既然如此，为何还要单独定义 R_{res} ？因为二者分工不同： f_p 、 f_n 是**运营指标**，用来算账，决定判官值不值得用； R_{res} 是**诊断指标**，用来解释为什么一个通用准确率很高的判官放到特定生成器上会失效，并指导我们换用什么样的判官。

这个模型有明显的简化： C_{miss} 在现实中很难估计；它假设各候选的错误互相独立；也没有计入现实结果回流后 f_p 、 f_n 逐步下降的效果。第 5 节的实验恰好可以测出 f_p 和 f_n ，把这个模型从纸面推向数据。

7 开放问题与局限

这一方案最大的弱点不在生成器，而在判官本身。以下问题目前没有答案：

- **判官从哪来？** 从数据学来的判官继承数据的局限，只能判断“不符合已知”；手写物理规则等于把人类已知的知识塞进去，在没有公认规律的领域无从下手。混合路线可能是出路，但边界如何划分仍不清楚。
- **替身有多可信？** 判官在训练范围内可能很准，在分布外却可能悄悄出错。我们需要让它知道自己何时不可信，并把这些情况交给现实验证。
- **钻漏洞问题（reward hacking）。** 若生成器被优化为“通过判官”，它可能学会利用判官的缺陷，产出在模拟里成立、在现实中失败的假设。
- **真正的新发现可能恰好违反判官。** 颠覆性的假设在旧模型里看起来就是错的。三路分流能缓解这一点，但前提是判官面对新现象时真的会报告“不确定”，而不是自信地判错；这本身需要实验检验。

判官越严格，越能挡住错误，也越可能挡住革命。如何在两者间取舍，可能是这一方向最核心的难题。

8 结论

自主科学发现需要的不是更多点子，而是一个能说“不”、也能说“我不知道”的判官。衡量判官好坏的关键不是它的通用准确率，而是它的错误与生成器有多独立。纯语言自评在缺乏独立外部反馈时容易缺少这样的判官，现实又太慢太贵，因此代理判官作为中间层值得认真检验。

本文不声称这一方案已经可行。我们提出的是一个可检验的主张、一个可在普通电脑上完成的最小实验、一个说明判官何时划算的成本模型，以及一组必须正面回答的问题。其中最难的一个是：怎样造出一个既能挡住错误、又不会挡住真正新发现的判官。

参考文献

- [1] D. Silver et al. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529:484–489, 2016.
- [2] A. Novikov et al. AlphaEvolve: A coding agent for scientific and algorithmic discovery. arXiv:2506.13131, 2025.
- [3] C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, D. Ha. The AI Scientist: Towards fully automated open-ended scientific discovery. arXiv:2408.06292, 2024.
- [4] J. Gottweis, W.-H. Weng, A. Daryin, T. Tu et al. Towards an AI co-scientist. arXiv:2502.18864, 2025.
- [5] Z. Yu et al. Large Discovery Models: Empirically-grounded model-based open-ended search. arXiv:2608.15669, 2026.